

Modelo Vetorial e BM25 sobre a Coleção Cranfield

Implementação, Avaliação e Análise de Erros

Gustavo Blois, NUSP 13688612

Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo (ICMC/USP), gustavobloisrr@usp.br
Trabalho Prático 1, SCC0282 Recuperação de Informação, 2º Sem/2026, Prof. Marcelo Manzato

1 Introdução

Sistemas de Recuperação de Informação (RI) ordenam documentos de uma coleção de acordo com sua relevância estimada para uma consulta. A coleção **Cranfield** (1400 resumos de artigos de engenharia aeronáutica, cobrindo aerodinâmica, estruturas, transferência de calor e aeroelasticidade, e 225 consultas com julgamentos de relevância graduados) é um dos primeiros e mais usados *benchmarks* para avaliar esses sistemas.

Este trabalho implementa, sem bibliotecas de RI que escondam o cálculo do *score*, dois modelos clássicos, o **modelo vetorial** (*tf-idf* com similaridade de cosseno) e o **modelo probabilístico BM25**, e os avalia com as métricas usuais. O objetivo não é só medir qual modelo tem a maior média, mas entender *por que* os dois discordam em certas consultas: como o pré-processamento, o comprimento dos documentos e a forma como cada modelo pondera a repetição de um termo interação para produzir rankings diferentes, e, em alguns casos, igualmente ruins.

2 Técnicas Utilizadas

2.1 Pré-processamento

O texto passa por tokenização, normalização para minúsculas, remoção de *stopwords* (lista fixa de 36 palavras em inglês) e *stemming* (Snowball para o inglês, pacote `opam stem`). As quatro configurações do item 1 ligam/desligam essas duas etapas independentemente: `raw`, `stopwords`, `stemming`, `stopwords+stemming`.

2.2 Índice invertido

O índice invertido é uma **hashtable de hashtables**: termo $\rightarrow$ (id do documento $\rightarrow$ tf). Verificar se um termo ocorre em um documento e obter sua frequência são, portanto, duas buscas em hashtable encadeadas, cada uma $O(1)$ esperado, em vez de uma busca linear em postings ou um acesso a uma matriz densa termo-documento.

O custo fica na *construção*: montar o índice exige um passe por todos os tokens de todos os documentos, $O(D \cdot \bar{W}) = O(\sum_d |d|)$, com $D = 1400$ documentos e $\bar{W} \approx 99,85$ o comprimento médio de documento (*avgdl*). Cada inserção é $O(1)$ amortizado, então o total é linear no corpus. O mesmo custo aparece ao montar as estatísticas globais (*idf* de cada termo, norma de cada documento): outro passe $O(\sum_d |d|)$, feito uma única vez e reaproveitado pelas 225 consultas. Como o BM25 e o vetorial só percorrem as *posting lists* dos termos da consulta, o custo de pontuar uma consulta é $O(\sum_{t \in q} df(t))$: proporcional a quão comuns são seus termos, não ao tamanho da coleção. O preço desse ganho por consulta é pagar, uma única vez, essa construção mais cara.

2.3 Modelo vetorial

Documentos e consultas são vetores no espaço dos termos do vocabulário, com peso $w(t, x) = (1 + \ln tf(t, x)) \cdot \ln(N/df(t))$ (tf logarítmico, idf logarítmico; sem normalização de documento na fórmula do peso porque o cosseno já normaliza): $\cos(q, d) = \frac{\sum_t w(t, q) w(t, d)}{\|q\| \|d\|}$ mede o ângulo entre os vetores, isto é, se consulta e documento enfatizam os mesmos termos proporcionalmente, independente do tamanho absoluto de cada um.

2.4 BM25

Implementado termo a termo (`lib/model.ml`), percorrendo a *posting list* de cada termo da consulta:

$$\text{score}(d, q) = \sum_{t \in q} \text{idf}(t) \cdot \frac{tf(t, d) (k_1 + 1)}{tf(t, d) + k_1 \left(1 - b + b \frac{|d|}{\text{avgdl}}\right)}, \quad \text{idf}(t) = \ln \left(1 + \frac{N - df(t) + 0,5}{df(t) + 0,5}\right)$$

k_1 controla a saturação da frequência de termo; b controla a normalização por tamanho do documento (em $b=0$ o termo entre parênteses vale sempre 1; em $b=1$ ele é $|d|/\text{avgdl}$). Diferente do vetorial, o BM25 não normaliza pelo tamanho da consulta e soma contribuições independentes por termo.

2.5 Métricas

Precision@10, Recall@10, F1@10, AP@all (média = MAP), AP@10, *Reciprocal Rank* (média = MRR) e NDCG@10 (ganho $g = 5 - \text{grau}$, desconto $\log_2$), calculadas por consulta e agregadas por média. Nas métricas binárias, relevante = grau ≥ 1 ; grau -1 e não julgados contam como não relevantes.

2.6 Ferramentas auxiliares

Todo o pipeline foi implementado em OCaml sem biblioteca de RI; só o *stemming* usa o pacote *opam stem*. Os gráficos deste relatório foram gerados com **gnuplot**, a partir de *scripts .gp* escritos pelo próprio programa (*recinf plot*), reproduzíveis junto com os experimentos.

3 Avaliação

Dataset: Cranfield, obtida em [University of Glasgow, Cranfield Collection](#) (1400 documentos, 225 consultas, qrels consulta doc grau). Os ids do arquivo de consultas não coincidem com a numeração dos qrels (que numera as consultas de 1 a 225 pela posição); o programa usa essa posição, mostrando também o id original quando relevante.

Configurações: 4 pré-processamentos $\times$ (vetorial + BM25 em grade $k_1 \in \{0,5; 1,2; 2,0\} \times b \in \{0; 0,75; 1\}$) = 40 execuções, cada uma nas 225 consultas. Resultados por consulta (*results/per_query.csv*) e agregados (*results/summary.csv*). Para comparar vetorial e BM25 em cada configuração, conto quantas consultas cada um vence, quantas empatam e quantas têm diferença “clara” ($|\Delta AP| \geq 0,1$) (*results/comparison_summary.csv*).

4 Resultados Obtidos e Análise

4.1 Efeito do pré-processamento (Item 1)

Pré-proc.	Modelo	P@10	R@10	F1@10	MAP	MRR	NDCG@10
raw	vetorial	0,2049	0,3361	0,2307	0,2506	0,4742	0,3051
raw	BM25	0,2098	0,3469	0,2367	0,2544	0,4926	0,3182
stopwords	vetorial	0,2067	0,3396	0,2329	0,2500	0,4728	0,3061
stopwords	BM25	0,2124	0,3540	0,2405	0,2559	0,4954	0,3224
stemming	vetorial	0,2164	0,3738	0,2476	0,2722	0,4851	0,3271
stemming	BM25	0,2169	0,3702	0,2472	0,2834	0,5305	0,3446
stopwords+stemming	vetorial	0,2173	0,3741	0,2483	0,2722	0,4849	0,3279
stopwords+stemming	BM25	0,2182	0,3730	0,2489	0,2861	0,5297	0,3481

Tabela 1: Métricas médias por pré-processamento (BM25 com $k_1=1,2$, $b=0,75$).




Figura 1: MAP, P@10 e R@10 por pré-processamento, vetorial vs. BM25.

O ganho relevante vem do *stemming*: as seis métricas melhoram com ele, nos dois modelos, então a conclusão não depende de olhar só uma. Uso o MAP para resumir os números por ser a única que considera o *ranking* inteiro, não só os 10 primeiros: MAP vetorial 0,2506 $\rightarrow$ 0,2722; BM25 0,2544 $\rightarrow$ 0,2861. O *stemming* une variações morfológicas de um mesmo conceito (p.ex. *ablate/ablating/ablation* $\rightarrow$ *ablat*) que, sem ele, nunca casariam entre consulta e documento. Ele também erra no sentido oposto, separando palavras que deveriam ficar juntas: *rarefaction* (consulta 52) vira *rarefact*, mas *rarefied* (em documentos sobre escoamento hipersônico rarefeito) vira *rarefi*: a mesma ideia, duas formas, dois stems diferentes (outro caso assim, verificado termo a termo, na Seção 4.6).

A remoção de *stopwords* isoladamente quase não muda o MAP (0,2506 $\rightarrow$ 0,2500 no vetorial), porque essas palavras já recebem idf baixo nos dois modelos: removê-las tira ruído que já pesava pouco. Combinar as duas

técnicas não soma os ganhos (MAP igual ao de *stemming* isolado): a maior parte do efeito já vem dele.

4.2 Vetorial vs. BM25 (Item 5)

Métrica	vetorial	BM25	Δ	venc. BM25	venc. vetor.	empates
MAP	0,2722	0,2861	+0,0139	125	91	9
MAP@10	0,2153	0,2284	+0,0131	106	67	52
P@10	0,2173	0,2182	+0,0009	51	43	131
R@10	0,3741	0,3730	-0,0012	51	43	131
MRR	0,4849	0,5297	+0,0448	86	54	85
NDCG@10	0,3279	0,3481	+0,0202	111	67	47

Tabela 2: Vetorial vs. BM25 ($k_1=1,2$, $b=0,75$, stopwords+stemming), 225 consultas.

O BM25 vence mais consultas do que perde em todas as métricas, mas a margem varia: ganho relativo de +9,2% em MRR contra +0,4% em P@10 e empate técnico em R@10 (131/225). Isso combina com a definição de cada métrica: o MRR depende só da posição do primeiro relevante (seu inverso), então um ganho grande nele indica que o BM25 acha o primeiro documento útil mais cedo. P@10/R@10 só contam quantos relevantes entram no corte de 10, sem ligar para a ordem entre eles; o BM25 ganhar pouco aí mostra que essa vantagem reordena o *ranking*, mas não coloca *mais* relevantes dentro do corte (o MAP, que olha o *ranking* inteiro, também capta essa reordenação).

4.3 Análise por consulta (Item 6)




Figura 2: AP@all por consulta, vetorial vs. BM25; consultas do item 6 destacadas.

Q (.l)	Modelo	Top-5 (^g = grau de relevância, 1 = melhor)	AP
<i>BM25 muito melhor</i>			
173 (264)	vetorial	532, 367 ¹ , 451 ¹ , 917, 29	0,583
173 (264)	BM25	367 ¹ , 451 ¹ , 532, 767, 917	1,000
143 (213)	vetorial	1068, 930, 1043 ¹ , 828, 953	0,244
143 (213)	BM25	1043 ¹ , 1068, 930, 1134, 828	0,625
<i>Vetorial muito melhor</i>			
183 (277)	vetorial	1243 ⁴ , 804 ⁴ , 1247 ⁴ , 808 ¹ , 811 ³	0,647
183 (277)	BM25	893, 811 ³ , 1226, 804 ⁴ , 808 ¹	0,292
148 (218)	vetorial	1048 ² , 1050 ² , 956, 1126, 761	0,462
148 (218)	BM25	956, 1126, 1048 ² , 1050 ² , 928	0,189
<i>Ambos fracos</i>			
13 (26)	vetorial	496, 903, 643, 313, 520	0,000
13 (26)	BM25	496, 903, 520, 313, 38	0,000
44 (79)	vetorial	1190, 862, 385, 1148, 236	0,000
44 (79)	BM25	103, 108, 1190, 1199, 1072	0,000

Tabela 3: Top-5 documentos das seis consultas do item 6 (sem sobrescrito = não relevante).

BM25 muito melhor. Em Q173 (2 relevantes), AP 0,583 → **1,000**. O não relevante mais bem colocado no vetorial (532, sobre estabilidade de mísseis) repete o termo raro *lyapunov* 3 vezes contra 2 no relevante 367, e por ser mais curto ($|d|=25,2$ vs. $35,4$) tem norma menor: sua similaridade (0,432) supera a do 367 (0,299), mesmo o 367 casando com *mais* termos da consulta (*linear*, *differenti*, *equat*, além de *lyapunov/stabil*). No BM25, a saturação de *tf* reduz a vantagem da repetição extra no 532 (contribuição 11,64 vs. 9,68 no 367), enquanto o 367 soma as contribuições dos termos extras (+8,33), superando o 532 (23,09 vs. 18,07). O cosseno recompensa foco estreito em um termo raro; o BM25 recompensa cobrir mais termos, porque cada um soma um valor próprio sem ser diluído pela norma do documento inteiro. Q143 segue o padrão: o único relevante no top-5 (1043) sobe da 3ª posição no vetorial para a 1ª no BM25.

Vetorial muito melhor. Em Q183 (13 relevantes), AP **0,647** → 0,292: o vetorial acerta os 5 primeiros com relevantes de vários graus. No BM25, o documento 893 (sobre calibração de tubos de Pitot, não relevante) fica em 1º (score 15,29) sem compartilhar *nenhum* termo temático da consulta (*sonic*, *boom*, *strength*); ele casa só com *what*, *factor*, *have*, *been*. A lista de *stopwords* usada não inclui essas palavras interrogativas/auxiliares, e nesta coleção elas são raras o bastante (*what* aparece em só 16 dos 1400 documentos) para receber um *idf* alto (4,44) sem carregar sinal sobre o assunto. Como o BM25 soma contribuições termo a termo, essas quatro palavras genéricas bastam para superar os documentos realmente relevantes; o vetorial sofre menos porque o mesmo produto interno é dividido pela norma do documento inteiro, que aqui inclui muitos outros termos irrelevantes ao *score*. Q148 é parecida: os dois relevantes do top-5 (1048, 1050) vão de 1º/2º no vetorial para 3º/4º no BM25.

Ambos fracos. Em Q13 (4 relevantes) e Q44 (3 relevantes), AP = 0 nos dois modelos: nenhum relevante aparece entre os 30 primeiros. Q13 é o caso mais revelador: o documento mais bem colocado por ambos (496, título quase idêntico ao da consulta: “a theory of transonic aileron buzz...”) está marcado como **não relevante** (grau -1) nos *qrels*; os 4 relevantes de fato (64, 265, 65, 311) tratam do mesmo fenômeno (interação onda de choque/camada limite) com vocabulário totalmente diferente (“*shock wave*”, “*boundary layer*”, “*vorticity*”), sem usar *aileron* ou *buzz*. O problema não é erro de cálculo, é a suposição de que casamento lexical implica relevância: o julgamento do Cranfield reflete uma noção de assunto mais profunda do que a sobreposição de palavras. Q44 é análoga: a consulta menciona a teoria “*chapman-enskog*”, termo raro ausente dos 3 documentos relevantes.

4.4 Parâmetros do BM25 (Item 7)

$k_1 \backslash b$	MAP			NDCG@10		
	0	0,75	1	0	0,75	1
0,5	0,2434	0,2689	0,2707	0,2980	0,3317	0,3315
1,2	0,2508	0,2861	0,2851	0,3067	0,3481	0,3452
2,0	0,2508	0,2917	0,2886	0,3100	0,3538	0,3510

Tabela 4: Grade de parâmetros do BM25 (stopwords+stemming), 225 consultas.




Figura 3: Efeito de b no BM25 por k_1 ; tracejado = vetorial.

b tem efeito muito maior que k_1 : $b=0 \rightarrow 0,75$ ganha até 0,04 de MAP em qualquer k_1 , enquanto variar k_1 com b fixo move o MAP em no máximo 0,007. Nesta coleção, normalizar pelo tamanho do documento importa mais que ajustar a saturação de tf : os documentos variam bastante em tamanho, e sem normalização ($b=0$) os longos acumulam tf bruto só por serem longos. $b=1$ não ajuda mais que $b=0,75$: a normalização completa penaliza demais alguns relevantes que são naturalmente mais longos que a média.

Consulta sensível a b : Q52. AP 0,207 ($b=0$) $\rightarrow$ **0,850** ($b=1$), $k_1=1,2$. Com $b=0$, o documento 798 (não relevante, $|d|=382$, quase $4\times$ a média) fica em 1º, na frente do relevante 326 (grau 4, $|d|=32$, bem mais curto que a média): sem normalização, o documento longo acumula mais ocorrências brutas só por ter mais texto. Com $b=1$, o 798 é penalizado proporcionalmente ao tamanho e o 326 assume a liderança (P@10 0,20 $\rightarrow$ 0,40, os 4 relevantes entram no *ranking*): exatamente o efeito que b deveria produzir.

4.5 Modificação de consultas (Item 8)

Cinco consultas foram escolhidas e reformuladas manualmente (ferramenta de apoio descrita na Seção 6); resultados completos em `results/modifications.csv`.

Q (.l)	mudança	AP vetor	AP BM25
14 (27)	removeu “papers on”	0,076 $\rightarrow$ 0,667	0,071 $\rightarrow$ 0,700
35 (61)	sinônimo “acoustic” $\rightarrow$ “sound” + removeu <i>boilerplate</i>	0,025 $\rightarrow$ 0,394	0,021 $\rightarrow$ 0,178
17 (32)	reformulação mais explícita	0,508 $\rightarrow$ 0,506	0,260 $\rightarrow$ 0,507
6 (10)	removeu “theoretical and experimental ... do we have”	0,050 $\rightarrow$ 0,075	0,160 $\rightarrow$ 0,171
22 (40)	reescrita com o vocabulário do documento relevante	0,000 $\rightarrow$ 1,000	0,000 $\rightarrow$ 1,000

Tabela 5: As cinco modificações, AP@all antes $\rightarrow$ depois.

Q14 e Q35 mostram o mesmo padrão: as consultas originais têm frases de preenchimento (“papers on”, “are there any ...dealing with”) que competem por peso contra os termos de conteúdo; ao removê-las, o *score* relativo do que importa sobe e os relevantes emergem nos dois modelos. Q17 reforça o achado da Seção 4.3: o BM25 responde melhor a uma reformulação que acrescenta termos que casam com mais relevantes (0,260 $\rightarrow$ 0,507), enquanto o cosseno, sensível à norma do documento, quase não se altera (0,508 $\rightarrow$ 0,506). Q22 é o caso mais extremo, continuação direta da Seção 4.6: como o documento relevante 68 não compartilha *nenhum stem* com a consulta original, a reformulação foi construída lendo o resumo do documento 68 e reescrevendo a consulta com esse vocabulário (*air, helium, simulation, viscous, hypersonic*). O resultado (AP 0 $\rightarrow$ 1 nos dois modelos) confirma o diagnóstico, mas com uma ressalva: não é uma troca por sinônimos da consulta original, é uma reescrita apoiada no texto do documento-alvo, uma forma de *expansão de consulta com oráculo* (escrita sabendo qual é o documento certo), mais forte do que uma reformulação real feita sem conhecer a resposta.

4.6 Análise de erros (Item 9)

O comando `recinf errors` lista, por consulta, os documentos não relevantes nas 5 primeiras posições (falsos positivos) e os relevantes fora do Top-10, inclusive nunca recuperados (falsos negativos); lista completa em `results/error_analysis.csv`. Dela, dois falsos positivos e um falso negativo entre os mais claros de explicar:

1. **Falso positivo: Q13, doc. 496** (1º nos dois modelos, grau -1), já discutido na Seção 4.3: título quase idêntico à consulta, mas explicitamente não relevante; os de fato relevantes usam vocabulário totalmente diferente para o mesmo fenômeno. O doc. 265, por exemplo, descreve exatamente o *aileron buzz* sem usar essas palavras: *aileron* vira “control surface”, *buzz* vira “instabilities”/“oscillatory behaviour”, e o *mechanism* perguntado na consulta é descrito como “interaction between shock waves and boundary layer”.
2. **Falso positivo: Q3, doc. 485** (“linear heat flow in a composite slab”, 1º, cosseno 0,46, BM25 21,1): a consulta é majoritariamente frase de preenchimento; só *composit* ($df=23$) e *slab* ($df=14$) carregam sinal, ambos raros, e bastam para o documento liderar nos dois modelos.
3. **Falso negativo: Q22, doc. 68** (único relevante, grau 1, **nunca recuperado**, score = 0): nenhum *stem* da consulta ocorre no documento. Ele contém *viscous*; a consulta usa *viscosity*. Deveriam casar, mas o *stemmer* reduz *viscosity* a *viscos* e mantém *viscous* como *viscous*: stems diferentes para a mesma família, fechando a única ponte lexical possível. Nenhum ajuste de k_1/b resolve isso, pois o documento nunca entra na lista de candidatos: é falha de vocabulário, não de *ranking* (ver Seção 4.5, Q22).

5 Considerações Finais

O BM25 ganha mais consultas do que perde em todas as métricas, mas a vantagem está concentrada em achar o primeiro relevante mais cedo (MRR, MAP), não em encaixar mais relevantes num corte fixo de 10 posições (onde P@10/R@10 empatam). Um critério prático de escolha: se a aplicação valoriza um bom resultado rápido, o MRR mais alto do BM25 pesa a favor dele; se depende de reunir vários relevantes numa janela fixa, os dois empatam nesta coleção, e a escolha recai em outros critérios (por exemplo, simplicidade de implementação).

O *stemming* é o ganho de pré-processamento mais importante, mas erra nos dois sentidos (junta demais em alguns casos, separa demais em outros, como *viscous/viscosity*). A lista fixa de *stopwords*, por não incluir palavras interrogativas/auxiliares, causou diretamente um falso positivo de alto impacto (Q183); ampliá-la é uma melhoria barata sugerida pelos próprios dados. b importa mais que k_1 nesta coleção, coerente com a grande variação de tamanho dos documentos. Por fim, parte dos casos ruins não é falha de modelo: são consultas cujos relevantes foram julgados por um critério de assunto mais profundo do que a sobreposição lexical que qualquer um dos dois modelos, ou o próprio *stemmer*, consegue captar.

6 Uso de Ferramentas de IA

Uma ferramenta de IA (Claude Code) foi usada de forma recorrente ao longo do desenvolvimento, como assistente de programação e de análise: na escrita e depuração de código OCaml, na exploração dos resultados dos experimentos (por exemplo, checar hipóteses termo a termo com `recinf explain`, ou montar ferramentas auxiliares para navegar pelos dados na escolha de consultas para os itens 6, 8 e 9) e na organização e redação deste relatório a partir desses resultados. As decisões de modelagem (fórmulas do vetorial e do BM25, configurações de pré-processamento e de parâmetros avaliadas) e a interpretação de cada resultado são do autor, que acompanhou e validou cada etapa.